

Relatório Classificação Utilizando Redes Neurais Multicamadas  
Disciplina: Tópicos em Aprendizado de Máquina  
Aluno: Gustavo Emanuel  
Professora: Aurora Trinidad Ramirez Pozo

## Introdução ao problema e ao dataset escolhido

A saúde mental tem se tornado um tema cada vez mais relevante em escala global, à medida que aumentam os casos de transtornos como depressão, ansiedade, esquizofrenia, entre outros. Esses transtornos psiquiátricos não apenas afetam significativamente o bem-estar emocional e psicológico dos indivíduos, mas também impactam diretamente sua qualidade de vida, desempenho profissional e relações sociais. A complexidade desses distúrbios exige uma abordagem ampla, que considere fatores sociais, culturais, ambientais e biológicos.

Com o avanço da tecnologia e da ciência de dados, diferentes abordagens têm sido utilizadas para investigar as causas, padrões e impactos da saúde mental. Uma das frentes de análise envolve dados coletados por meio de pesquisas com trabalhadores da área de tecnologia, os quais revelam como fatores do ambiente de trabalho influenciam o bem-estar psicológico e a procura por tratamento e com isso a análise utilizando um classificador baseado em Perceptron Multicamadas (MLP - Multi-Layer Perceptron) em um problema de classificação supervisionada. A partir de conjuntos de dados previamente conhecidos, explorei o processo de treinamento de redes neurais, realizando ajustes nos hiperparâmetros e avaliando a performance do modelo em termos de acurácia e outras métricas relevantes.

- Base 01

O primeiro dataset utilizado neste trabalho é proveniente de uma pesquisa realizada em 2014, cujo objetivo principal foi investigar as atitudes em relação à saúde mental e a frequência de transtornos mentais no ambiente de trabalho, especialmente entre profissionais da área de tecnologia. A pesquisa foi aplicada de forma anônima e coletou informações diversas, incluindo dados demográficos como idade e gênero, além de aspectos relacionados à vida profissional, como o tipo de contratação (autônomo ou empregado), e a percepção dos respondentes sobre o suporte oferecido pelas empresas em relação à saúde mental.

Os participantes responderam questões sobre diagnóstico e tratamento de transtornos mentais, o conforto em discutir saúde mental com colegas e gestores, e a forma como suas empresas lidam com questões de saúde mental em comparação à saúde física.

- Base 02

Este dataset é oriundo de uma pesquisa global realizada com o objetivo de acompanhar tendências relacionadas à saúde mental. Os dados abrangem uma variedade de variáveis, incluindo níveis de estresse, depressão, ansiedade, bem-estar subjetivo e uso de serviços de saúde mental. A pesquisa envolveu participantes de diferentes origens demográficas, considerando aspectos como gênero, situação profissional e região geográfica. O principal propósito deste conjunto de dados é fornecer uma compreensão mais ampla sobre as mudanças na saúde mental da população ao longo do período analisado, permitindo identificar padrões e apoiar a

formulação de políticas públicas e estratégias de intervenção mais eficazes em escala global.

- Base 03

Este dataset de EEG contém aproximadamente 1.000 atributos extraídos de sinais eletroencefalográficos, com o objetivo de auxiliar na identificação de transtornos psiquiátricos. O EEG é uma técnica não invasiva que registra a atividade elétrica cerebral, captando diferentes padrões de ondas (como alfa, beta, teta e delta), além de métricas de conectividade neural e características temporais e espectrais.

## Metodologia utilizada para pré-processamento e modelagem

- Base 01

Para a construção do modelo, foi realizada uma etapa de pré-processamento dos dados. Inicialmente, foram removidas colunas não categóricas e consideradas irrelevantes para o modelo, tais como 'Timestamp', 'comments' e 'state', por não contribuírem de forma significativa para a previsão do target. Em seguida, foi feito o tratamento de outliers na coluna "Age", uma vez que valores extremos poderiam distorcer os resultados do modelo. Para lidar com variáveis categóricas, aplicou-se a técnica de codificação utilizando o LabelEncoder, transformando essas variáveis em representações numéricas que pudessem ser interpretadas pelo algoritmo. Além disso, os dados foram normalizados por meio do StandardScaler, o que garantiu que todas as variáveis tivessem a mesma escala. O alvo da modelagem (variável *y*) indica se o indivíduo procurou ou não tratamento para uma condição de saúde mental.

- Base 02

O processo de preparação dos dados para essa base iniciou-se com a verificação de valores ausentes nas colunas. Constatou-se que apenas a coluna "self\_employed" continha valores nulos, os quais foram preenchidos com o valor categórico 'None', evitando assim a perda de informações. Em seguida, optou-se por transformar o problema em uma classificação binária, removendo todos os registros em que a variável "Growing\_Stress" apresentava o valor "maybe", com isso, ela foi escolhida como variável alvo.

Para garantir que apenas informações relevantes fossem utilizadas, foram excluídas colunas consideradas não informativas para a modelagem, como "timestamp" e "country". As variáveis categóricas foram então transformadas em variáveis numéricas utilizando o LabelEncoder, tornando-as compatíveis com o algoritmo.

Na sequência, registros duplicados foram removidos para evitar vieses e redundâncias no treinamento do modelo. Para reduzir a dimensionalidade e manter apenas os atributos mais relevantes, foi aplicada uma técnica de seleção de características utilizando o algoritmo Random Forest, sendo selecionadas as nove variáveis mais importantes de acordo com a relevância atribuída pelo modelo. Por fim, os dados foram normalizados utilizando o Standard Scaler, assegurando que todas as variáveis tivessem a mesma escala e contribuíssem de forma equilibrada no processo de aprendizado da rede.

- Base 03

O pré-processamento dos dados teve início com a remoção de colunas consideradas não interessantes para a tarefa de classificação, mantendo-se no conjunto apenas as informações mais relevantes. Em seguida, foi realizado um filtro das colunas contendo os valores de EEG.

Para garantir que todas as variáveis numéricas estivessem na mesma escala e contribuíssem de maneira uniforme no treinamento, os dados foram normalizados utilizando o StandardScaler. A variável alvo (`main.disorder`), que representa o transtorno associado ao indivíduo, foi transformada em valores numéricos por meio do Label Encoder, sendo assim um problema multi-classe.

Como a distribuição das classes estava desequilibrada, o conjunto de dados foi submetido a uma técnica de balanceamento utilizando o SMOTE (Synthetic Minority Over-sampling Technique). Essa abordagem gera exemplos sintéticos da classe minoritária, permitindo que o modelo aprenda de forma mais equilibrada e evite viés em relação à classe majoritária.

- Descrição do algoritmo de aprendizado

Para a modelagem do problema de classificação binária, foi desenvolvida uma rede neural do tipo MLP utilizando a biblioteca PyTorch. A arquitetura do modelo conta com uma camada de entrada compatível com o número de variáveis independentes (`input_dim`), uma camada oculta com 64 neurônios e ativação ReLU, seguida de uma camada de dropout com taxa de 50% para reduzir o overfitting. Por fim, uma camada de saída com dois neurônios foi utilizada, representando as duas classes da variável-alvo (`output_dim = 2`), com previsão tratada por meio de softmax.

O treinamento do modelo foi conduzido utilizando validação cruzada com 5 subdivisões (`n_splits = 5`), garantindo que a proporção entre as classes fosse mantida em cada partição. Em cada fold, os dados foram divididos em conjuntos de treino e validação, os quais foram convertidos em DataLoaders para permitir treinamento em batch de tamanho 32.

Os modelos foram treinados durante 100 e 20 épocas , respectivamente, para cada fold, utilizando o otimizador Adam com taxa de aprendizado de 0,001 e a função de perda CrossEntropyLoss, adequada para tarefas de classificação. A cada época, os pesos da rede foram ajustados com base no erro entre as previsões do modelo e os valores reais. Após o treinamento, o modelo era avaliado no conjunto de validação correspondente, onde se calculava a acurácia e as probabilidades da classe positiva (classe 1) por meio da função softmax. As métricas e probabilidades obtidas em cada fold foram armazenadas para posterior análise de desempenho geral da rede.

O modelo da base 03 também emprega uma rede MLP, porém com foco em uma tarefa de classificação multiclasse, com sete classes possíveis. Sua arquitetura é semelhante, com uma camada oculta de 64 neurônios, função ReLU e Dropout de 30%.

### Resultados obtidos e análise das métricas de desempenho

Para avaliar o desempenho do modelo de classificação treinado, utilizou-se a função `classification_report` da biblioteca `scikit-learn`. Essa função compara os rótulos reais das amostras com as previsões feitas pelo modelo e gera um relatório contendo métricas detalhadas para cada classe. As métricas calculadas incluem precisão (proporção de previsões corretas entre todas as feitas para uma classe), revocação (proporção de amostras corretamente identificadas entre todas as pertencentes a uma classe) e o F1-score, que representa a média harmônica entre precisão e revocação. O relatório também apresenta o suporte, ou seja, a quantidade de amostras reais em cada classe. Para facilitar a interpretação dos resultados, cada classe foi nomeada de forma descritiva como “Classe 0”, “Classe 1”, até o número total de classes do problema. O relatório final foi impresso ao término da validação cruzada, permitindo uma análise quantitativa do desempenho do modelo em todas as categorias previstas.

- Base 01

	Precisão	Revocação	F1-Score	Suporte
0	0,73	0,74	0,74	124
1	0,74	0,72	0,74	126
Acurácia	0,74			250

- Base 02

	Precisão	Revocação	F1-Score	Suporte
0	0,82	0,72	0,77	3412
1	0,77	0,86	0,81	3774
Acurácia	0,79			7186

- Base 03

	Precisão	Revocação	F1-Score	Suporte
0	0,62	0,58	0,60	500
1	0,68	0,74	0,71	500
2	0,81	0,90	0,85	500
3	0,61	0,46	0,52	500
4	0,93	0,97	0,95	500
5	0,74	0,77	0,75	500
6	0,64	0,66	0,65	500
Acurácia	0,72			3500

Na Base 01, o modelo apresenta desempenho equilibrado entre as duas classes, com acurácia geral de 74%. A precisão e a revocação são similares entre as classes, o que indica que o modelo está relativamente balanceado em sua capacidade de identificar corretamente ambas as categorias. No entanto, o suporte é relativamente pequeno, o que pode limitar a generalização do modelo.

Na Base 02, tem acurácia de 79%. O modelo mostra boa revocação para a classe 1 (86%), o que indica uma boa capacidade de identificar corretamente essa categoria. Já a classe 0 apresentou uma revocação um pouco menor (72%), sugerindo que o modelo comete mais falsos negativos nessa classe. Ainda assim, os resultados são bastante satisfatórios, em parte devido ao maior número de amostras.

A Base 03, se trata de um problema de classificação multiclasse com sete categorias. A acurácia foi de 72%, o que é razoável, mas observa-se uma grande variação no desempenho entre as classes. A classe 4 obteve um F1-score muito alto (0,95),

enquanto a classe 3 teve um desempenho bastante inferior (F1-score de 0,52). Isso pode indicar que algumas classes estão mais bem representadas nos dados ou são mais fáceis de distinguir. Como estratégia de melhoria, pode-se considerar remover ou agrupar classes com baixo desempenho, especialmente se elas forem pouco representativas ou pouco relevantes para a tarefa final. Além disso, técnicas como ajuste de pesos na função de perda ou oversampling podem ser utilizadas para lidar com o desbalanceamento entre as classes.